



POLICY PAPER 2026-03 · OCTOBRE 2026

L'augmentation des factures d'IA et la montée de l'open weight

Ce que les données OpenRouter disent des volumes, des tarifs et du basculement vers les modèles ouverts

Antonin Bergeaud
Paul Delbouve
Etienne Grass

EN BREF

- La facture d'IA des entreprises augmente alors que le coût unitaire d'un token baisse fortement : l'essentiel de la hausse vient des volumes, non des tarifs.
- Sur OpenRouter, la part des modèles à poids ouverts passe de 40 % à 73 % des tokens entre janvier et août 2026, et de 11 % à 34 % des dépenses.
- Les utilisateurs rattachés à la France consacrent 31,0 % de leurs dépenses aux modèles ouverts, contre 19,3 % à l'échelle mondiale.
- Les appels adressés aux modèles ouverts sont quatre fois plus longs qu'en janvier, mais leur coût moyen n'est multiplié que par 3,8 : l'avantage de coût subsiste.
- La réallocation vers l'ouvert explique 43 % de la baisse simulée du coût d'un panier français constant, et ouvre une marge de déploiement plutôt qu'une économie automatique.

Les entreprises américaines interrogées en mars 2026 par la [Réserve fédérale d'Atlanta](#) prévoient de consacrer 2 068 dollars par salarié à l'intelligence artificielle cette année, contre 1 358 dollars en 2025, soit une hausse de plus de 50 %. Le passage à l'échelle commence ainsi à faire apparaître une facture que les premières expérimentations avaient en partie ignorée. Plusieurs grandes entreprises ont commencé à plafonner les dépenses, à restreindre certains usages ou à orienter leurs salariés vers des modèles moins coûteux ([Financial Times](#)). Le développement d'agents réalisant des opérations répétées renforce cette pression en multipliant les appels et les tokens consommés, conduisant ces entreprises à mettre en place des dispositifs de suivi et de contrôle inspirés de ceux utilisés pour le cloud ([Wall Street Journal](#)). Certaines entreprises qui avaient ouvert largement l'accès commencent désormais à introduire des limites d'usage et à demander quelles utilisations justifient réellement leur coût.

Faut-il y voir la fin de « l'âge d'or » de l'IA, comme on l'entend de plus en plus ? Pas nécessairement. L'explosion de la facture vient d'abord des volumes consommés. Le coût pour atteindre un niveau de performance donné a, lui, fortement baissé : le [Stanford AI Index Report](#), publié en 2026, estime qu'il a été divisé par plus de 280 entre novembre 2022 et octobre 2024 pour une performance comparable à celle de GPT-3.5. Mais les entreprises ne s'arrêtent évidemment plus à ce niveau de performance et consomment beaucoup plus. Elles déploient davantage d'applications, utilisent des agents et transmettent des contextes de plus en plus longs. Ce phénomène rappelle le paradoxe de Jevons, ou effet rebond, fréquent lorsqu'une baisse du coût d'usage d'une technologie stimule sa consommation.

À mesure que ces usages se développent, les entreprises apprennent aussi à mieux les organiser. Le montant de la facture dépend alors largement de la manière dont elles utilisent les modèles, à la fois via le type d'informations qu'elles leur transmettent, des opérations qu'elles leur font répéter et du modèle choisi pour chaque tâche. Une entreprise peut donc réduire ses coûts en modifiant l'architecture de ses usages, par exemple en réservant les modèles les plus coûteux aux tâches qui exigent réellement leurs capacités. La maîtrise de la facture passe ainsi par des choix d'organisation et de technologie, au-delà de la seule négociation des tarifs.


Depuis le début de 2026, les usages observés suggèrent un changement dans la manière dont les modèles sont choisis : les utilisateurs les adaptent davantage à chaque usage afin d'en réduire le coût, sans dégradation apparente de la qualité. Pour l'étudier, nous utilisons les données d'[OpenRouter](#), une plateforme largement utilisée par les développeurs et les entreprises, qui permet d'accéder à plusieurs centaines de modèles par une même interface et de passer facilement de l'un à l'autre. Ses utilisateurs sont donc particulièrement bien placés pour comparer les offres et adapter rapidement leurs choix. Ils ne sont pas représentatifs de l'ensemble des utilisateurs de l'IA, mais peuvent être en avance sur des pratiques susceptibles de se diffuser ensuite plus largement. Nous nous intéressons ainsi à l'évolution de leurs arbitrages plutôt qu'aux niveaux observés ou aux parts de marché des différents modèles.

Ces données font apparaître une évolution nette. Entre le début de janvier 2026 et la semaine du 10 août, la part des modèles ouverts passe d'environ 40 % à 73 % des tokens consommés. Leur part dans les dépenses augmente également, de 11 % à 34 %. Les modèles ouverts occupent donc une place croissante dans les budgets, tout en représentant une proportion beaucoup plus importante des volumes traités. Cet écart éclaire leur intérêt économique pour les utilisateurs intensifs, sans mesurer directement l'économie réalisée pour accomplir une même tâche.

Trois limites doivent néanmoins être gardées en tête. D'abord, OpenRouter ne représente qu'une partie limitée du marché : une grande part des usages passe directement par les API des éditeurs ou par d'autres intermédiaires. Ensuite, la plateforme est particulièrement utilisée pour construire des workflows, ce qui surreprésente probablement les usages agentiques par rapport à l'usage moyen.

Enfin, les éditeurs cherchent désormais à y améliorer leur position, notamment au moyen de promotions ciblées. Ces caractéristiques invitent à interpréter avec prudence les niveaux observés et renforcent l'intérêt de raisonner principalement sur leurs évolutions.¹

Figure 1. Part des modèles ouverts entre janvier 2025 et août 2026



Notes : Part des modèles ouverts dans le total des tokens (gauche) et des dépenses des utilisateurs (droite), en %. Moyenne arithmétique des parts hebdomadaires sur la semaine courante et les trois précédentes. Semaines du 6 janvier 2025 au 10 août 2026. Source : OpenRouter

En France, un usage de l'ouvert légèrement plus présent


Les utilisateurs rattachés à la France consacrent une part plus importante de leur facture OpenRouter aux modèles ouverts². En juillet 2026, ceux-ci représentent 31,0 % des dépenses françaises enregistrées, contre 19,3 % à l'échelle mondiale. La photographie des producteurs précise quels modèles se trouvent derrière cette différence.

Anthropic reste le premier destinataire des dépenses dans les deux périmètres, mais sa part est de 32,6 % en France, contre 49,0 % dans le monde. Google occupe une place beaucoup plus importante dans les dépenses françaises, avec 21,7 %, contre 10,6 % à l'échelle mondiale. OpenAI complète le trio de tête. Ensemble, ces trois producteurs représentent 69,8 % des dépenses françaises et 77,9 % des dépenses mondiales observées sur la plateforme.

¹ Les données d'OpenRouter ont néanmoins le grand avantage d'être accessibles aux chercheurs. Nous avons ainsi obtenu de leurs équipes des informations détaillées sur 1 125 000 milliards de tokens, 7,3 millions d'utilisateurs et 116 milliards de requêtes couvrant la période de janvier 2025 à août 2026. Il n'existe pas à notre connaissance de base de source publique et officielle proposant des informations à ce niveau de détail et qui seraient représentatives. Des alternatives existent notamment (1) celles d'[Artificial Analysis](#) qui ont l'avantage d'être construites sur un index d'analyse de la valeur, mais sont davantage agrégées. Ces données démontrent l'intérêt économique à s'appuyer davantage sur les modèles ouverts. Elles montrent aussi que les prix ont baissé depuis la sortie du modèle Kimi k3 ; (2) celles de [Ramp](#), issues de leurs clients qui correspondent à des données réelles de dépenses des entreprises mais dont la représentativité est également difficile à établir et enfin (3) celles d'autres routeurs comme Vercel ou Requesty qui possèdent a priori les mêmes limites que celles d'OpenRouter.

² Un modèle d'IA est défini en partie par ses poids, c'est-à-dire les milliards de paramètres appris pendant son entraînement qui déterminent la manière dont il répond. Dans ce texte, nous appelons « ouverts » les modèles dont les poids sont accessibles et peuvent être téléchargés. Une entreprise peut alors les faire fonctionner sur ses propres infrastructures ou chez un fournisseur de cloud, et dispose généralement de davantage de latitude pour les adapter à ses besoins. À l'inverse, les modèles fermés sont principalement accessibles comme un service, notamment par une API, sans accès à leurs poids. Cette qualification ne signifie pas que tout est ouvert. Les données d'entraînement, le code utilisé pour entraîner le modèle ou certains détails techniques peuvent rester privés, et les licences peuvent imposer des restrictions. Le terme plus précis est donc « modèle à poids ouverts » (*open-weight model*).

Figure 2. Répartition des dépenses, des requêtes et des tokens par producteur, France et monde



Notes : Juillet 2026. Chaque mesure est rapportée au total du périmètre concerné, tous producteurs confondus. Le monde inclut la France. Les onze producteurs affichés réunissent les dix premiers en dépenses de chaque périmètre, dans un ordre commun fondé sur les dépenses mondiales ; tous les autres figurent dans « Autres ». Les couleurs distinguent le statut des modèles, et non celui du producteur. Tokens d'entrée et de sortie enregistrés, cache et raisonnement déjà inclus. Source : OpenRouter

La place plus importante de l'ouvert dans les dépenses françaises s'appuie notamment sur Z.ai, l'éditeur des modèles GLM, et sur DeepSeek. À eux deux, ces producteurs représentent 20,9 % des dépenses en France, contre 13,0 % dans le monde. DeepSeek occupe une place particulièrement importante en volume, avec 30,8 % des tokens consommés en France, contre 17,0 % à l'échelle mondiale. Mistral AI est également davantage présent dans les dépenses françaises, mais son poids reste limité : 0,49 %, contre 0,14 % dans le monde.

La hiérarchie change toutefois selon la mesure retenue. En France, Google reçoit le plus grand nombre de requêtes, DeepSeek traite le plus de tokens et Anthropic concentre le plus de dépenses. À l'échelle mondiale, Google et DeepSeek arrivent également en tête pour les requêtes et les tokens. Le nombre d'appels adressés à un producteur donne donc une image très partielle de son poids dans la facture. Celui-ci dépend aussi de la tarification des modèles et de l'intensité des usages qui leur sont confiés.

Cette intensité varie fortement y compris entre modèles ouverts. En France, une requête adressée aux modèles de Z.ai contient en moyenne environ 52 400 tokens, contre 8 600 pour DeepSeek, en additionnant les entrées et les sorties. Un nombre limité d'appels peut ainsi représenter un volume très important de contenu traité et une dépense élevée, une concentration que l'on retrouve aussi dans les usages, quelques utilisateurs représentent souvent la majorité de la consommation de tokens dans une entreprise. De même, on observe une très grande disparité de gamme de prix entre les fournisseurs de modèles open-source. DeepSeek se positionne ainsi sur des modèles à très bas prix de l'ordre de 0,5 \$/MTokens (dollars par millions de tokens) en moyenne, au contraire de Moonshot.ai, Z.ai ou Qwen qui proposent des gammes de modèles variés dont les prix peuvent avoisiner 1.5\$/MTokens et jusqu'à 6\$/MTokens pour les modèles les plus performants.

La qualité détermine les substitutions économiquement possibles

L'augmentation de la part des modèles ouverts dans les tokens pourrait laisser penser que les entreprises ont renoncé à monter en valeur pour contenir leurs dépenses. Mais elles peuvent aussi désormais obtenir avec des modèles ouverts des capacités qui justifiaient auparavant le recours à des modèles fermés. La figure 3 illustre cette possibilité de substitution. En juillet 2026, GLM 5.2 obtient une performance proche de Claude Opus 4.7 sur le benchmark édité par Artificial analysis, avec respectivement 52,6 et 55 points. Sa dépense observée par million de tokens est pourtant de 0,40


dollar, contre 1,74 dollar pour Claude Opus 4.7. Ces écarts portent toutefois sur les usages effectivement observés, dont le contenu peut différer entre modèles.

La figure 4 montre que cette baisse des dépenses unitaires s'accompagne d'une progression vers des modèles mieux notés. Pour la classe de qualité 20–30, la dépense par million de tokens passe de 1,46 dollar en mars–avril 2025 à 0,28 dollar en juillet–août 2026. Dans le même temps, la classe 40–50 devient la plus utilisée parmi celles représentées, tandis que les requêtes adressées aux modèles notés 50–60 augmentent rapidement. En fin de période, les classes 20–30, 30–40 et 40–50 présentent même des dépenses moyennes par token très proches. L'accès à des capacités plus élevées ne s'accompagne donc pas systématiquement d'un coût unitaire supérieur.

Pour une entreprise, l'intérêt de changer de modèle dépend de ce qu'apporte encore le modèle le plus coûteux à ses tâches concrètes. Une avance de performance peut justifier son prix si elle évite des erreurs ou réduit une vérification humaine coûteuse. Lorsque plusieurs modèles fournissent un résultat suffisamment fiable, cette avance perd une partie de sa valeur économique. Un modèle ouvert peut alors remplacer un modèle fermé sans imposer une baisse des exigences. Mais le coût de changer de modèle, et notamment d'abandonner le réflexe d'utiliser celui proposant les plus hauts scores de qualité peut être élevé. Comme on l'a vu sur la figure 2, même sur une plateforme qui facilite fortement le changement de modèle, les offres les mieux notées concentrent une grande partie des dépenses. Cette persistance ne signifie pas qu'elles sont utilisées pour toutes les opérations : les modèles notés au moins 60 représentent moins de 1 % des appels, mais plus de 15 % de la facture. Hors d'une plateforme unifiée, des contraintes d'intégration supplémentaires peuvent ralentir encore les réallocations, même si les données mobilisées ici ne permettent pas d'en mesurer l'importance.


Pour évaluer le coût économique de l'IA, il faut toutefois dépasser le prix des tokens et raisonner en coût total d'un résultat utilisable, en incluant notamment les reprises et le contrôle humain. Les travaux qui valorisent un workflow complet plutôt qu'un token montrent que, pour des volumes réalistes, le coût des erreurs et de leur vérification peut dépasser de deux à trois ordres de grandeur la facture de tokens lorsqu'un modèle manque de fiabilité. La fiabilité sur les tâches effectivement réalisées par l'organisation devient alors un critère de choix plus pertinent que le seul score obtenu sur un benchmark. Les économies peuvent dès lors venir d'une répartition plus fine des opérations entre modèles, mais aussi de la suppression d'appels inutiles, du réemploi de résultats déjà obtenus ou d'une réduction du contrôle humain. La maîtrise des coûts dépend ainsi de l'organisation de l'ensemble du traitement autant que du modèle utilisé pour chaque appel.

Figure 3. Performance et coût d'usage des modèles en juillet 2026



Notes : La surface de chaque bulle est proportionnelle aux tokens consommés. Vert : poids ouverts ; rouge : modèles fermés. La dépense par million de tokens est le rapport des dépenses enregistrées aux tokens d'entrée et de sortie, cache compris, présenté sur une échelle logarithmique. Les 191 modèles notés et classés représentés couvrent 94,6 % des tokens du périmètre retenu. Source : OpenRouter et scores de performance Artificial Analysis.

Figure 4. Coût d'usage et diffusion par classe de performance



Notes : Modèles ouverts et fermés réunis. Lissage sur quatre semaines : rapport des sommes des dépenses et des tokens à gauche, moyenne des requêtes hebdomadaires à droite. Données du 17 mars 2025 au 9 août 2026. Coûts en échelle logarithmique, hors activité identifiée comme facturée directement aux fournisseurs ; requêtes tous appels. Modèles sans score exclus, couverture présentée séparément. La composition des modèles et des appels peut varier au sein des classes. Source : OpenRouter et scores de performance Artificial Analysis..


Des appels plus longs, dont l'avantage de coût subsiste

Les appels adressés aux modèles ouverts sont devenus beaucoup plus longs, tout en restant moins coûteux que ceux adressés aux modèles fermés. En France, au cours des quatre dernières semaines de notre échantillon, qui se termine le 9 août 2026, un appel à un modèle ouvert contient environ 10 000 tokens, contre 4 600 pour un modèle fermé. Pourtant, la dépense pour 1 000 appels s'élève à 1,44 dollar pour les modèles ouverts, contre 3,34 dollars pour les modèles fermés, soit 57 % de moins. Dans

le monde, l'écart de dépense par appel atteint 77 %. Ces comparaisons portent sur les consommations observées, sans supposer que les modèles accomplissent les mêmes tâches.

Cet avantage relatif coexiste toutefois avec une hausse du coût des appels ouverts au cours du temps. En France, leur longueur moyenne est multipliée par quatre entre les premières semaines de 2026 et la fin de la période. La dépense pour 1 000 appels passe dans le même temps de 0,38 à 1,44 dollar, soit une multiplication par 3,8. Le léger recul du coût moyen par token ne compense donc pas l'allongement des appels causé par l'usage massif de l'IA agentique à partir de 2026. Les modèles ouverts restent moins coûteux par appel que les modèles fermés, mais chaque appel ouvert coûte désormais davantage qu'au début de l'année.

Figure 5. L'avantage de coût de l'ouvert subsiste malgré l'allongement des appels



Notes : ratios des sommes sur quatre semaines complètes, du 5 janvier–1er février au 13 juillet–9 août 2026. Les appels identifiés comme facturés directement aux fournisseurs sont exclus des requêtes, tokens et dépenses ; les appels à dépense nulle sont conservés. Tokens d'entrée et de sortie, cache et raisonnement déjà inclus. Populations et modèles variables. Source : OpenRouter.

La progression française de l'ouvert porte ainsi surtout sur l'intensité des appels. Sur l'ensemble des flux enregistrés, sa part dans les requêtes passe d'environ 48 % à 54 %, tandis que sa part dans les tokens passe de 34 % à 71 %. Une partie de cet écart vient aussi du raccourcissement des appels fermés. La forte hausse des volumes ouverts correspond donc à un déplacement beaucoup plus limité du nombre d'appels.

Nos données ne permettent qu'une décomposition partielle de ces tokens, mais elles donnent une indication sur l'origine de cet allongement. Les entrées déclarées comme « mises en cache » expliquent comptablement 79 % de la hausse des tokens par appel ouvert en France et 92 % dans le monde. Les tokens de raisonnement contribuent à moins de 1 % de cette hausse dans les deux périmètres. L'essentiel de l'augmentation provient donc de contextes plus longs ou réutilisés d'un appel à l'autre, beaucoup moins d'une augmentation des tokens consacrés au raisonnement.

Concrètement, une application peut transmettre le même dossier à plusieurs étapes d'un traitement. Une première requête peut demander de l'analyser, une deuxième d'en extraire une information et une troisième de vérifier le résultat. Le contenu du dossier est alors compté dans les tokens à chaque appel, même lorsqu'il est réutilisé depuis un cache. Le volume total peut ainsi augmenter beaucoup plus vite que la quantité d'informations nouvelles effectivement transmise. Cette hausse se répercute par ailleurs moins que proportionnellement sur la facture, car les entrées servies depuis le cache sont généralement facturées à une fraction du tarif d'entrée standard, souvent de l'ordre du dixième. Cela contribue à expliquer pourquoi, alors que la longueur moyenne des appels ouverts est multipliée par quatre, leur coût moyen n'est multiplié que par 3,8.

Cette évolution peut correspondre à des usages économiquement utiles. Une fenêtre de contexte plus longue permet par exemple de transmettre directement un dossier complet, sans devoir sélectionner au préalable les passages pertinents. Réutiliser ce contexte à plusieurs étapes peut aussi simplifier la conception d'une application ou d'un workflow. Mais certaines répétitions peuvent n'apporter aucun gain et constituer au contraire une source d'économies potentielles. Le nombre de tokens ne permet donc pas, à lui seul, de savoir si l'entreprise réalise davantage de travail utile ou si elle mobilise simplement davantage de ressources pour obtenir un résultat comparable.


Les économies unitaires ouvrent une marge de déploiement

Une facture croissante peut masquer une baisse du coût nécessaire pour financer un volume donné. Pour en apprécier l'ampleur, nous construisons un panier de tokens à partir des consommations de mai 2026, puis conservons son volume et sa répartition par classes de performance. Nous calculons ce que ce même panier coûterait aux coûts moyens observés en fin de période. Les modèles ouverts et fermés sont réunis dans cette comparaison.

En France, un panier représentant 100 dollars en mai est valorisé à environ 53 dollars aux coûts moyens de fin de période dans les mêmes classes de performance. Le résultat américain est proche, à 57 dollars. Mais si l'on conserve exactement les versions de modèles du panier initial et le nombre de tokens confié à chacune, les indices restent voisins de 100 dans les deux pays. La baisse observée à répartition de performance constante ne correspond donc pas à une réduction uniforme du coût des modèles déjà utilisés.

La progression de l'ouvert représente une part substantielle de cette baisse. Si l'on conserve, dans chaque classe de performance, les parts de tokens adressés aux modèles ouverts et fermés en mai, tout en appliquant les coûts moyens observés en fin de période, le panier français est valorisé à 73 dollars. Avec les parts observées en fin de période, il vaut 53 dollars. La réallocation vers l'ouvert représente ainsi 20 points sur les 47 points de baisse, soit 43 %. Aux États-Unis, elle représente 21 points sur 43, soit 49 %.

Figure 6. La réallocation vers l'ouvert représente 43 % de la baisse simulée du coût du panier français



Notes : référence du 4 au 31 mai 2026 ; fin de période du 13 juillet au 9 août. Volume de tokens de mai maintenu dans chaque classe de performance de cinq points. Les deux simulations appliquent les coûts moyens par token de fin de période par statut d'ouverture, avec les non-classés isolés, en conservant leurs parts initiales ou en utilisant leurs parts finales dans chaque classe. Leur écart mesure la réallocation aux coûts finaux ; la contribution des modèles non classés est inférieure à 0,01 point. Source : OpenRouter

Le reste de la baisse provient des changements de coûts moyens à l'intérieur de l'ouvert et du fermé. Ces baisses de tarifs ne sont pas indépendantes de la diffusion de l'ouvert, puisque la disponibilité de substituts à poids ouverts, chinois comme américains, par exemple avec la famille Nemotron, contraint la tarification des modèles fermés. L'attribution de 43 % constitue à cet égard une borne inférieure de l'effet total de l'open weight.

Ils peuvent refléter des baisses de tarifs, des réallocations entre modèles d'une même catégorie ou des changements dans la composition des appels. Le recours accru à l'ouvert explique donc une partie de la baisse du coût du panier, mais pas sa totalité.

Une décomposition plus complète est présentée dans le tableau 1, qui distingue les modèles déjà utilisés en mai de ceux qui étaient absents du panier initial. Les deux exercices captent en partie les mêmes mouvements. L'arrivée d'un nouveau modèle ouvert, par exemple, peut à la fois accroître la part de l'ouvert et déplacer les usages vers un modèle absent en mai. Les contributions issues des deux décompositions ne doivent donc pas être additionnées.

Ces montants mesurent une possibilité comptable, et non une économie effectivement réalisée par chaque entreprise. Les classes rapprochent les modèles selon leur performance sur le benchmark, sans garantir qu'ils soient interchangeable pour toutes les tâches. Le calcul ne maintient pas non plus constants les utilisateurs ou la composition des appels, notamment la part du cache et des sorties. Il ne mesure donc ni le coût d'un travail strictement identique ni l'effet causal de l'adoption de modèles ouverts.

Tableau 1. Décomposition du prix d'un usage d'IA entre mai et juillet 2026

Décomposition du coût du panier	France	États-Unis
Référence de mai	100,00	100,00
Coûts finaux avec parts initiales par statut	72,91	78,07
Coûts finaux avec parts finales par statut	52,76	57,00

Décomposition du coût du panier	France	États-Unis
Baisse totale du panier en points	47,24	43,00
Dont réallocation vers l'ouvert en points	20,15	21,07
Dont coûts à parts constantes en points	27,09	21,93
Dont variation des parts non classées en points	-0,0038	0,0011
Part de la baisse attribuée à la réallocation vers l'ouvert	42,7 %	49,0 %

Notes : Les contributions sont exprimées en points d'indice, sur une dépense initiale normalisée à 100. Les légers écarts de somme dans le tableau proviennent des arrondis.

Quel volume d'activité supplémentaire les économies unitaires permettent-elles de financer ?

Aux coûts observés en fin de période, le budget qui finançait le panier français de mai permettrait d'acheter 90 % de tokens supplémentaires, contre 75 % pour le panier américain. La progression de l'ouvert contribue fortement à cette marge. En France, appliquer les coûts finaux tout en conservant les parts initiales de l'ouvert et du fermé ne permettrait de financer que 37 % de tokens supplémentaires. La réallocation vers l'ouvert porte cette capacité à 90 %. Le calcul maintient constante la répartition par classe de performance ; il ne mesure pas une hausse équivalente du nombre de tâches réussies.


Une partie de cette marge peut être absorbée par la consommation supplémentaire qu'elle rend attractive. Des applications jusque-là trop coûteuses deviennent envisageables et d'autres utilisations apparaissent. De même, pour des usages déjà déployés, les utilisateurs peuvent transmettre davantage de contexte ou multiplier les appels. La baisse des coûts peut donc réduire la dépense, être entièrement réinvestie dans davantage d'usage, voire conduire à une hausse de la facture.

L'élasticité-prix mesure cette réaction des volumes au prix. Une élasticité de $-0,1$ signifie qu'une baisse de prix de 1 % suscite, toutes choses égales par ailleurs, environ 0,1 % de consommation supplémentaire. La dépense diminue alors, mais moins que le prix. Le seuil de -1 correspond à une dépense localement constante : la hausse des volumes compense la baisse du prix. Avec une réaction plus forte, par exemple une élasticité de $-1,5$, la dépense augmente, on est alors dans le cadre du paradoxe de Jevons.

Cette élasticité est difficile à estimer dans un marché où les modèles et les usages changent rapidement. Une baisse de la dépense par token peut provenir d'un tarif plus bas, mais aussi du choix de modèles différents. La hausse du trafic d'un modèle moins cher peut, de son côté, refléter un transfert depuis ses concurrents plutôt qu'une augmentation de la consommation totale. Il faut donc exploiter des baisses tarifaires sur des versions identifiées et suivre les mêmes comptes tous modèles confondus.

Nous utilisons les promotions de juillet 2026 sur GPT-5.6 Terra et Luna. Les baisses successives des 27 et 30 juillet réduisent leurs tarifs effectifs de 60 % et 90 % (figure 7), respectivement, sur OpenRouter via le service OpenAI standard. L'exposition de chaque compte est calculée à partir de ses usages avant l'annonce. Si une offre représente 40 % de sa facture initiale et que son tarif baisse de moitié, le coût de son panier initial diminue théoriquement de 20 %. Nous comparons ensuite l'évolution de la consommation totale des comptes plus ou moins exposés, en tenant compte de leur activité initiale et des évolutions communes à chaque pays.

Figure 7. Les promotions de juillet s'accompagnent d'une forte hausse des volumes des modèles concernés



Notes : service OpenAI standard ; cellules dont les quatre champs BYOK sont renseignés et égaux à zéro. Tarif annoncé à gauche, tokens quotidiens d'entrée et de sortie à droite. Base 100 : tarif antérieur au 27 juillet et moyenne quotidienne des tokens du 13 au 26 juillet. Données du 13 juillet au 12 août 2026, sans lissage. Les tarifs concernent l'entrée hors cache et la sortie ; la quantité inclut les tokens en cache. Modèles fermés, épisode unique avec changements de service concomitants. Comparaison descriptive, sans identification causale ni suivi à population constante. Sources : OpenRouter, OpenAI et calculs des auteurs.

Le suivi de 13 052 comptes dans six pays donne une estimation d'environ $-0,36$. Nous retenons donc $-0,4$ comme élasticité centrale pour les simulations. Ce choix reste incertain : l'épisode est court et les résultats sont sensibles au poids des gros consommateurs. Sa transposition au panier français constitue une hypothèse de travail, et non une mesure précise de l'élasticité. Nous l'accompagnons donc d'un scénario sans réaction des volumes et d'un scénario de réaction forte, à $-1,5$.

Le tableau distingue les économies unitaires et la consommation qu'elles peuvent financer. À parts ouvert/fermé inchangées au sein de chaque classe de performance, l'évolution des coûts moyens ramène le coût du panier français de 100 à 72,9. La réallocation vers l'ouvert le réduit ensuite à 52,8. Elle représente ainsi environ 43 % de la baisse du coût unitaire. Pour chaque scénario, nous calculons la réaction des volumes à ces deux niveaux de coût afin d'isoler ce qu'ajoute la réallocation vers l'ouvert.

Tableau 2. Économies unitaires, pour une facture initiale à 100.

Contribution à la facture	Sans réaction $\varepsilon = 0$	Central $\varepsilon = -0,4$	Réaction forte $\varepsilon = -1,5$
Évolution des coûts moyens, à parts ouvert/fermé initiales	-27,1	-27,1	-27,1
Économie supplémentaire liée à la réallocation vers l'ouvert, à volume fixe	-20,1	-20,1	-20,1
Hausse de la dépense liée aux volumes, sans cette réallocation	0,0	+9,8	+44,2
Effet supplémentaire de la réaction des volumes, après réallocation vers l'ouvert	0,0	+5,6	+40,7
Facture finale	52,8	68,1	137,7

Notes : panier du 4–31 mai 2026, valorisé aux coûts du 13 juillet–9 août, à répartition constante par classe de performance. Réallocation valorisée aux coûts finaux, puis réaction des volumes simulée à élasticité constante. Les coûts moyens combinent tarifs et composition des usages. L'attribution dépend de cet ordre de calcul ; elle ne mesure pas un effet causal de l'ouverture. Les scénarios extrêmes ne sont pas des bornes statistiques. Écarts éventuels dus aux arrondis. Source : OpenRouter, calculs des auteurs.

Dans le scénario central, la facture diminue de 32 %, malgré une hausse de 29 % des tokens consommés. Sans progression de la part de l'ouvert, elle ne diminuerait que de 17 %, tandis que les volumes augmenteraient de 13 %. La réallocation vers l'ouvert fait ainsi passer l'indice de dépense de 82,7 à 68,1, soit 14,6 points de facture en moins après prise en compte de la consommation supplémentaire qu'elle entraîne. Une partie de l'économie unitaire est donc réinvestie dans davantage d'usage, tandis que le reste réduit effectivement la facture.

Le scénario de réaction forte illustre une autre possibilité. La facture atteint alors 137,7, contre 117,1 sans progression de l'ouvert : les économies unitaires suscitent une expansion des volumes suffisamment forte pour porter la dépense au-dessus de son niveau initial. La progression de l'ouvert peut ainsi accroître fortement les possibilités de déploiement tout en augmentant la facture. Ce résultat dépend de la réaction supposée des utilisateurs et ne signifie pas que l'adoption de modèles ouverts entraîne nécessairement une hausse des dépenses.

Ces simulations isolent la consommation supplémentaire suscitée par la baisse des coûts. Une croissance des usages indépendante de cette baisse peut encore s'y ajouter. Une facture en hausse reste donc compatible avec une forte diminution du coût unitaire. Son interprétation dépend de ce que financent les volumes supplémentaires : davantage de tâches utiles, davantage de contexte ou simplement des appels redondants. Pour comprendre l'évolution de la dépense, il faut ainsi distinguer la baisse du coût unitaire, la réaction des volumes et l'extension des usages.

Implications pour les choix de déploiement

Les coûts et les volumes observés sur OpenRouter ne suffisent pas à déterminer la stratégie optimale de chaque organisation. Ils suggèrent néanmoins un cadre de décision pour les utilisateurs de modèles de langage : mesurer le coût total d'utilisation de l'IA pour une tâche, l'automatisation d'une tâche au niveau de qualité attendu, éviter les appels et les volumes de tokens inutiles, puis décider si les économies et gains ainsi dégagées doivent réduire la dépense ou financer de nouveaux usages. À partir

de ces résultats, cette dernière section présente plusieurs principes et pistes de réflexion pour éclairer les choix des organisations sur le déploiement des modèles d'IA.

La maîtrise de la facture commence par le coût d'une tâche accomplie au niveau de fiabilité requis. Celui-ci comprend l'ensemble des tentatives nécessaires et le temps de contrôle humain. Une économie sur les appels peut être annulée par le coût des corrections supplémentaires. Un modèle plus coûteux peut au contraire éviter ces reprises. Les scores de performance aident à sélectionner les offres à tester, mais seule une évaluation sur les tâches de l'organisation permet d'apprécier cet arbitrage.

L'optimisation doit aussi porter sur la quantité de traitement nécessaire à chaque résultat. Réutiliser une réponse ou sélectionner les informations utiles peut éviter des appels redondants. Le cache réduit le coût de certaines répétitions, sans supprimer la nécessité d'examiner leur utilité. Des règles d'arrêt peuvent limiter les boucles qui n'améliorent plus le résultat. Ces choix peuvent faire baisser la consommation par tâche, même lorsque l'organisation augmente le nombre de tâches confiées à l'IA. Le changement de modèle constitue l'un des moyens de réduire la facture ; la conception de l'application peut en réduire directement les volumes.

Un dernier arbitrage, que nos données ne permettent pas de chiffrer, concerne le mode d'exploitation. Pour une activité volumineuse et prévisible, une capacité d'inférence dédiée peut se comparer au paiement à l'usage, notamment lorsque les poids du modèle sont disponibles et sa licence le permet. Le coût passe alors en partie d'une dépense par appel à une capacité qu'il faut financer et exploiter. Les simulations d'intégrateurs disponibles donnent les ordres de grandeur. Pour environ trente milliards de tokens par mois, l'exécution en propre d'un modèle ouvert de trente milliards de paramètres revient sur trois ans à environ un dixième du coût des API de frontière. Le même exercice montre cependant que louer ces mêmes poids auprès d'un hébergeur reste moins cher que de les exécuter soi-même, et que le seuil de rentabilité contre les API se situe vers quelques centaines de millions de tokens mensuels. L'économie vient donc du passage à l'ouvert plus que de la propriété de l'infrastructure, dont la justification tient à la résidence des données, au droit d'ajustement et à la stabilité tarifaire.

Son intérêt dépend de son taux d'utilisation et des compétences nécessaires à son fonctionnement. Une activité irrégulière peut mieux s'accommoder d'un service à l'usage. Les données OpenRouter ne chiffrant pas l'économie de ce changement d'architecture.

La capacité de comparer les solutions a elle-même un coût fixe (dont l'amortissement dépend des volumes d'utilisation). Des tests métier réutilisables peuvent réduire le travail nécessaire à chaque nouvel arbitrage. La portabilité des applications préserve la possibilité de changer de fournisseur lorsque le gain justifie les vérifications. Ces investissements peuvent être rentables pour des usages intensifs et disproportionnés pour une petite organisation. Mutualiser des évaluations sur des tâches bien définies aiderait les petites entreprises et administrations à comparer les offres sans recommencer l'ensemble du travail.

Ces principes ont une implication particulière pour les acheteurs publics. Une comparaison en coût par tâche validée permettrait de rapprocher la dépense du service attendu, avec des exigences explicites de sécurité et de fiabilité. Elle laisserait ouverte la possibilité de retenir un modèle fermé plus cher lorsque son avantage est utile, ou un modèle ouvert lorsque ses capacités suffisent. La part de l'ouvert et le nombre de tokens consommés ne constituent pas, en eux-mêmes, des objectifs de performance.

Les économies ainsi dégagées peuvent être conservées ou consacrées à de nouveaux usages. Le temps libéré ne devient pas automatiquement une économie budgétaire ; il peut aussi améliorer le service ou permettre d'absorber davantage d'activité. La décision d'étendre le déploiement doit préciser lequel de ces gains est attendu et comment il sera vérifié. Une facture croissante peut être justifiée par davantage de travail utile, tandis qu'une facture en baisse peut masquer des coûts reportés sur les salariés. Le suivi conjoint du coût complet et des résultats obtenus permet de décider quels usages méritent d'être étendus.

Auteurs

Antonin Bergeaud, HEC Paris et LIFT.

Paul Delbouve, Paris School of Economics, FIL et LIFT.

Etienne Grass, Capgemini.

Les auteurs remercient Justin Summerville, d'OpenRouter, pour l'accès aux données. Le contenu de cette note n'engage que ses auteurs et non Capgemini.

À propos du LIFT

Le Laboratoire de l'Innovation et du Futur du Travail (LIFT) est un laboratoire de recherche d'HEC Paris consacré à l'analyse de l'impact de l'intelligence artificielle sur les entreprises, l'emploi, l'innovation et la croissance. Il associe des chercheurs académiques et des praticiens autour de six axes de travail, produit des données originales et publie régulièrement notes, études et indicateurs à destination des décideurs publics et privés.

Les publications du LIFT

Les Policy Papers présentent, dans un format court, des résultats empiriques et leurs implications pour la décision publique et privée. Les Working Papers présentent des travaux de recherche en cours. Les trackers du LIFT donnent accès à des indicateurs actualisés sur la diffusion de l'IA. Les opinions exprimées n'engagent que leurs auteurs et ne représentent pas la position de leurs employeurs et institutions, ni celle des partenaires du laboratoire.

Citer ce document

Bergeaud, A., Delbouve, P. et Grass, E. (2026), « L'augmentation des factures d'IA et la montée de l'open weight », LIFT Policy Paper 2026-03, HEC Paris.

Contact

LIFT – HEC Paris, 1 rue de la Libération, 78351 Jouy-en-Josas

lift@hec.fr · heclift.github.io/website

Document publié sous licence Creative Commons CC BY 4.0. Reproduction autorisée avec mention de la source.

LIFT

LABORATOIRE DE L'INNOVATION
ET DU FUTUR DU TRAVAIL

